

中芯国际文档解析项目

开工会

2025 年 12 月 26 日

会议议程

01 项目背景

02 需求分析

03 项目计划

04 项目协作


05 风险应对

项目背景介绍

中芯国际 SMIC 文档解析开发项目


主要是为了对PDF、PPT、Word、Excel等多种格式文件以及图片、表格、流程图等内容进行解析，将非结构化数据转化为结构化数据并利用。

基于大模型算法构建文档要素抽取引擎，实现对PDF、PPT、Word、Excel等文档以及文档内图片、表格、流程图等复杂数据的解析分析，最终形成可支持智能问答系统、AI数字员工、光刻机异常分析助手、PDE培训数字员工、QE/CE稽核数字员工等应用的功能模块。




底部贴边文本样例，button text sample，button text sample，button text sample


需求示例1如下图



需求示例1如下图



产品需求分析鱼骨图



最终交付目标为 100%，时间 2025/1/19

需求类别	子类别	需求概要	MOI 满足情况	MOI 满足度
解析	文字解析	能够正确识别全字符集，对文档中的标题、正文及其层级内容可以正确区别，识别中日英等混合语言的文档。	不支持页眉页脚解析	95%
	图片理解	对流程图、图表、图文混合图像等图片类型进行正确的文字提取和语义理解，提供必要的跨页合并和结构化数据输出，支持多中图片文件类型的解析。	Caption 理解效果需要提升 不支持图表解析为结构化数据	70%
	表格解析	能够正确按照表格拓普输出结构化数据，对表格中的嵌入图片正确理解，支持跨页表格以及 excel 中的离散表格识别提取	不支持跨页表格拼接 不支持是否合并单元格输出控制	80%
	公式解析	正确识别 Office 文档中各个位置的公式，并输出为 markdown 公式语法	行级、表格内公式无法识别	70%
性能	可扩展 / 高并发	支持计算资源的横向扩展，支持 500 人高并发访问	支持计算资源扩展，支持任务并发配置及文件内图片解析并发	100%
	高可用	支持系统宕机自动恢复，高负载持续运行，并在多节点部署，支持文档优先解析策略。	计算节点为无状态服务节点	100%
可视化	可观测	对系统的监控状态检测，提供任务监控及审计日志，具有自动清理数据的能力。	基础的信息都有记录，待信息整合 不支持 API 调用后自动清理数据	70%
API	接口对接	支持单一 API 对各种类型文档解析，API 可配置是否返回原始文件、数据清除、批量解析、状态推送等	已支持基础的 API 接口，待支持若干可配置功能	80%